

Lectura 11

Ajuste de curvas

Dr. Luciano Ponzellini Marinelli
lucianoponzellini@uca.edu.ar

Facultad de Química e Ingeniería
Rosario, Argentina

Notas de clase
04 noviembre 2025



Organización

MOTIVACIÓN

REGRESIÓN LINEAL

FORMULACIÓN DEL PROBLEMA

MÍNIMOS CUADRADOS

IMPLEMENTACIONES

MOTIVACIÓN


Motivación del problema

Motivación

Ajuste de datos.

Note las diferencias con
INTERPOLAR

Regresión lineal



REGRESIÓN LINEAL

Regresión lineal

- En general, si nos dan un conjunto de puntos

$$\{(x_k, y_k), \quad k = 1, \dots, N\}.$$

- Buscamos determinar una relación $y = f(x)$.
- Comenzamos suponiendo una función lineal

$$y = f(x) = Ax + B,$$

siendo A y B coeficientes a determinar.




Figura 5.2 Distancias verticales entre los puntos $\{(x_k, y_k)\}$ y la recta $y = Ax + B$.

Regresión lineal

- Notemos que

$$f(x_k) = Ax_k + B = y_k + e_k, \quad k = 1, \dots, N.$$

siendo e_k el **error de medición**.

- Es decir

$$e_k = f(x_k) - y_k, \quad k = 1, \dots, N$$

también conocidos como **residuos** o **desviaciones**.

- ¿Cómo hallamos la mejor aproximación lineal de la forma $y = Ax + B$ que 'minimice' la distancia a los puntos?
- La recta $y = Ax + B$ se conoce como **recta de regresión lineal**.
- Existen varios errores que podemos usar para minimizar.

Regresión lineal

Error máximo: $E_{\infty}(f) = \max\{|f(x_k) - y_k| : 1 \leq k \leq N\},$

Error medio: $E_1(f) = \frac{1}{N} \sum_{k=1}^N |f(x_k) - y_k|,$

Error cuadrático medio: $E_2(f) = \left(\frac{1}{N} \sum_{k=1}^N |f(x_k) - y_k|^2 \right)^{1/2}.$

- El error $E_2(f)$ también se conoce como ECM.
- En general se usa $E_2(f)$ por tener mejores propiedades de derivación.
- Minimizar $E_2(f)$ equivale a minimizar el valor $N(E_2(f))^2$, esto es

$$N(E_2(f))^2 = \sum_{k=1}^N |f(x_k) - y_k|^2.$$

Regresión lineal

Teorema 5.1 (Recta de regresión en mínimos cuadrados). Supongamos que $\{(x_k, y_k)\}_{k=1}^N$ son N puntos cuyas abscisas $\{x_k\}_{k=1}^N$ son distintas. Entonces, los coeficientes de la recta de regresión

$$y = Ax + B$$

son la solución del siguiente sistema lineal, conocido como las *ecuaciones normales de Gauss*:

$$(10) \quad \begin{aligned} \left(\sum_{k=1}^N x_k^2 \right) A + \left(\sum_{k=1}^N x_k \right) B &= \sum_{k=1}^N x_k y_k, \\ \left(\sum_{k=1}^N x_k \right) A + NB &= \sum_{k=1}^N y_k. \end{aligned}$$

Regresión lineal

Demostración. Si empezamos con la recta $y = Ax + B$, entonces la distancia vertical d_k desde el punto (x_k, y_k) hasta el punto $(x_k, Ax_k + B)$ de la recta es $d_k = |Ax_k + B - y_k|$ (véase la Figura 5.2). Debemos minimizar la suma de los cuadrados de las distancias verticales d_k :

$$(11) \quad E(A, B) = \sum_{k=1}^N (Ax_k + B - y_k)^2 = \sum_{k=1}^N d_k^2.$$

El valor mínimo de la función $E(A, B)$ se determina igualando a cero las derivadas parciales $\partial E / \partial A$ y $\partial E / \partial B$ y resolviendo las ecuaciones que resultan

Regresión lineal

en A y B . Nótese que $\{x_k\}$ e $\{y_k\}$ son constantes en la expresión (11) ¡y que A y B son las variables! Fijando B y derivando $E(A, B)$ respecto de A , obtenemos

$$(12) \quad \frac{\partial E(A, B)}{\partial A} = \sum_{k=1}^N 2(Ax_k + B - y_k)(x_k) = 2 \sum_{k=1}^N (Ax_k^2 + Bx_k - x_k y_k).$$

Ahora fijamos A y, derivando $E(A, B)$ respecto de B , obtenemos

$$(13) \quad \frac{\partial E(A, B)}{\partial B} = \sum_{k=1}^N 2(Ax_k + B - y_k) = 2 \sum_{k=1}^N (Ax_k + B - y_k).$$

Regresión lineal

Igualando a cero las derivadas parciales obtenidas en (12) y (13) y usando la propiedad distributiva de la suma, obtenemos

$$(14) \quad 0 = \sum_{k=1}^N (Ax_k^2 + Bx_k - x_k y_k) = A \sum_{k=1}^N x_k^2 + B \sum_{k=1}^N x_k - \sum_{k=1}^N x_k y_k,$$

$$(15) \quad 0 = \sum_{k=1}^N (Ax_k + B - y_k) = A \sum_{k=1}^N x_k + NB - \sum_{k=1}^N y_k. \quad \bullet$$

- Estas ecuaciones normales de Gauss pueden resolverse usando técnicas conocidas.
- Pueden hacerse algunas mejoras para que la matriz de coeficientes resulte bien condicionada.

Regresión lineal

- Consideremos los siguientes datos:

x_k	y_k
-1	10.0
0	9.0
1	7.0
2	5.0
3	4.0
4	3.0
5	0.0
6	-1.0

- Construyamos las ecuaciones normales de Gauss.
- Resolvamos el sistema para obtener la curva.
- Ploteamos en una misma gráfica.


FORMULACIÓN DEL PROBLEMA

Formulación del problema

Formulación del problema

$$M = \{(x_1, y_1); (x_2, y_2); \dots; (x_n, y_n)\}$$

$$a \leq x_i \leq b \quad i=1, \dots, n$$



Donde en general los valores y_i son producto de alguna medición lo cual implica que pueden existir errores o incertezas

En general se cuenta además con información adicional del fenómeno que representan los datos (i.e. que comportamiento deberían presentar)

Formulación del problema

Formulación del problema

ESQUEMA PROPUESTO en base a la información previa se elige una
“BASE DE FUNCIONES”

$$\phi = \{\phi_1, \phi_2, \dots, \phi_k\}$$

$$\phi_i(\text{continua}) : [a, b] \rightarrow \mathbb{R} \quad i = 1, \dots, k$$

IMPORTANTE $k \ll n$


Ejemplos

$$\phi = \{1, x\} \quad \phi = \{\sin(x), \sin(2x), \cos(x), \cos(2x)\}$$

$$\phi = \{1, x, \exp(x)\}$$

Formulación del problema

Formulación del problema



Consideremos el conjunto generado por todas las funciones de la forma:

$$F(x) = \sum_{j=1}^k c_j \phi_j(x)$$

$$c_j = \text{ctes. (parametros)}$$

Cómo elegir las $\phi_j(x)$? (criterio)

Cómo determinar la “mejor” $F(x)$? (medida)

MÍNIMOS CUADRADOS

Formulación del problema

CRITERIO: Ajuste por mínimos cuadrados

Mínimos cuadrados. Es decir se buscan los parámetros C_j^* tal que hagan mínima la función

$$E(c_1, \dots, c_k) = \left(\sum_{i=1}^n (F(x_i) - y_i)^2 \right)^{1/2}$$

la solución $p^* = (c_1^*, \dots, c_k^*)$ es tal

$$E(p^*) = \min_{p \in \mathbb{R}^k} E(p) \quad \therefore \quad F(x) = \sum_{j=1}^k c_j^* \phi_j(x)$$

Formulación del problema

Cómo lo resuelvo?

$$E(p) = E(c_1, \dots, c_k)$$

Es un campo escalar de k variables. En consecuencia para que E tenga un mínimo en p^* es necesario que $\nabla E(p^*) = 0$; es decir sus derivadas parciales respecto de los parámetros c_i en p^* deberán ser todas nulas.

$$E^2(p) = \sum_{i=1}^n (F(x_i) - y_i)^2$$

$$\left. \frac{\partial E}{\partial c_r} \right|_{p^*} = 2 \sum_{i=1}^n (F(x_i) - y_i) \left. \frac{\partial F(x_i)}{\partial c_r} \right|_{p^*} = 0 \quad r = 1, 2, \dots, k$$

$$\text{donde} \quad F^*(x_i) = \sum_{j=1}^k c_j^* \phi_j(x_i) \quad , \quad \left. \frac{\partial F(x_i)}{\partial c_r} \right|_{p^*} = \phi_r(x_i)$$

Formulación del problema

Cómo lo resuelvo?

Reemplazando ...

$$\sum_{i=1}^n \left[\sum_{j=1}^k c_j^* \phi_j(x_i) - y_i \right] \phi_r(x_i) = 0 \quad r = 1, 2, \dots, k$$

$$\sum_{i=1}^n \left[\sum_{j=1}^k c_j^* \phi_j(x_i) \phi_r(x_i) \right] = \sum_{i=1}^n y_i \phi_r(x_i)$$

$$\sum_{j=1}^k c_j^* \left[\sum_{i=1}^n \phi_j(x_i) \phi_r(x_i) \right] = \sum_{i=1}^n y_i \phi_r(x_i)$$

CONOCIDO !



SISTEMA LINEAL k x k

Incógnitas c_j^*

IMPLEMENTACIONES

ajustepoly.m

`ajustbase.m/base.m`

Bibliografía

- **[KiCh1994]** D. Kincaid - W. Cheney, *Análisis Numérico. Las matemáticas del cálculo científico*, Addison-Wesley Iberoamericana, Delaware, 1994.
- **[MaFi2000]** J.M. Mathews - K.D. Fink, *Métodos Numéricos con MATLAB*, 3era Ed., Pearson Prentice Hall, Madrid, 2000.
- **[Mole2008]** C.B. Moler, *Numerical computing with MATLAB*, 2da. Ed., SIAM, Philadelphia, 2008.
- **[SPMK2023]** J.A. Semitiel, L. Ponzellini Marinelli & A.I. Kurdobrin, *Notas de Clases de Matemática Aplicada de Ingeniería Eléctrica e Ingeniería Electrónica*, FCEIA, UNR, 2023.
- **[SiSo2010]** J.W. Signorelli, J. Sorribas, *Notas de Clases, Informática Aplicada y Métodos Computacionales*, FCEIA, UNR, 2010.