



RESUMEN DE TEORÍA - SEGUNDO PARCIAL MCN

Métodos y Cómputos Numéricos - UCA Rosario

Lic. en Ciencia de Datos

Alumno: Agustín Formenti

Temas: Sistemas de Ecuaciones No Lineales + Interpolación + Ajuste de Curvas



ÍNDICE

1. Sistemas de Ecuaciones No Lineales (SENL)

- 1.1 Conceptos básicos
- 1.2 Método de Punto Fijo
- 1.3 Método de Newton-Raphson

2. Interpolación Polinomial

- 2.1 Conceptos básicos
- 2.2 Método directo (Vandermonde)
- 2.3 Interpolación de Lagrange

3. Ajuste de Curvas

- 3.1 Regresión lineal
 - 3.2 Mínimos cuadrados
 - 3.3 Ecuaciones normales de Gauss
-

1. SISTEMAS DE ECUACIONES NO LINEALES (SENL) {#1-senl}

1.1 ¿Qué es un SENL?

Un **Sistema de Ecuaciones No Lineales (SENL)** es un conjunto de ecuaciones donde al menos una contiene términos no lineales (cuadráticos, exponenciales, trigonométricos, etc.).

Notación general:

$$F(\mathbf{x}) \equiv 0$$

Donde:

- $\mathbf{x} = (x_1, x_2, \dots, x_n)$ es el vector de incógnitas

- $\mathbf{F}(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_n(\mathbf{x}))$ es el vector de funciones

Ejemplo en 2D:

$$f_1(x, y) \equiv x^2 - 2x - y + 0.5 \equiv 0$$

$$f_2(x, y) \equiv x^2 + 4y^2 - 4 \equiv 0$$

Estas ecuaciones definen **curvas en el plano**. Una **raíz** es un punto (p^*, q^*) donde se intersectan ambas curvas.

Concepto clave: RAÍZ

Una raíz o solución del SENL es un punto donde TODAS las funciones valen cero simultáneamente:

$$f_1(p^*, q^*) = 0$$

$$f_2(p^*, q^*) = 0$$

1.2 MÉTODO DE PUNTO FIJO (PF)

Idea fundamental:

Transformamos el sistema $\mathbf{F}(\mathbf{x}) = \mathbf{0}$ en un sistema equivalente de la forma:

$$x = g_1(x, y)$$

$$y = g_2(x, y)$$

Las funciones g_1 y g_2 se llaman **GENERATRICES**.

Definición de Punto Fijo:

Un punto (p^*, q^*) es un **punto fijo** si:

$$p^* = g_1(p^*, q^*)$$

$$q^* = g_2(p^*, q^*)$$

Es decir, el punto "no se mueve" al aplicar las generatrices.

Esquema iterativo:

Partiendo de un punto inicial (p_0, q_0) , generamos una sucesión:

Iteración $k = 0, 1, 2, \dots$

$$p_{\{k+1\}} = g_1(p_k, q_k)$$

$$q_{\{k+1\}} = g_2(p_k, q_k)$$

Si la sucesión converge $\rightarrow$ llegamos al punto fijo $\rightarrow$ resolvemos el SENL.

TEOREMA DE CONVERGENCIA (caso 2D):

Para que el método **CONVERJA** a (p^*, q^*) , debe cumplirse:

$$|\partial g_1 / \partial x| + |\partial g_1 / \partial y| < 1$$

$$|\partial g_2 / \partial x| + |\partial g_2 / \partial y| < 1$$

En un entorno del punto fijo y con (p_0, q_0) **suficientemente cerca** de (p^*, q^*) .

Forma equivalente (norma infinito):

$$\|J(x^*)\|_{\infty} < 1$$

Donde J es la matriz Jacobiana de las generatrices.

IMPORTANTE:

- Si las condiciones NO se cumplen $\rightarrow$ el método **puede diverger** o converger
- El **punto inicial** es crítico
- Diferentes generatrices pueden dar diferentes resultados
- Siempre hay que **verificar convergencia** antes de confiar en el resultado

Caso 3D:

Para tres variables (x, y, z) :

$$|\partial g_1 / \partial x| + |\partial g_1 / \partial y| + |\partial g_1 / \partial z| < 1$$

$$|\partial g_2 / \partial x| + |\partial g_2 / \partial y| + |\partial g_2 / \partial z| < 1$$

$$|\partial g_3 / \partial x| + |\partial g_3 / \partial y| + |\partial g_3 / \partial z| < 1$$

1.3 MÉTODO DE NEWTON-RAPHSON (NR) PARA SENL

Idea fundamental:

Es una **extensión natural** del método de Newton-Raphson de una variable al caso de varias variables.

Recordatorio (1 variable):

$$x_{n+1} = x_n - f(x_n) / f'(x_n)$$

Caso multivariable (2D):

$$P_{k+1} = P_k - [J(P_k)]^{-1} * F(P_k)$$

Donde:

- $\mathbf{P}_k = (x_k, y_k)$ es la aproximación en la iteración k
- $\mathbf{J}(\mathbf{P}_k)$ es la **matriz Jacobiana** evaluada en $\mathbf{P}_k$
- $\mathbf{F}(\mathbf{P}_k)$ es el vector de funciones evaluado en $\mathbf{P}_k$

Matriz Jacobiana:

$$\mathbf{J}(x,y) = \begin{bmatrix} \partial f_1 / \partial x & \partial f_1 / \partial y \\ \partial f_2 / \partial x & \partial f_2 / \partial y \end{bmatrix}$$

Esquema iterativo (algoritmo):

Paso 1: Evaluar $\mathbf{F}(\mathbf{P}_k)$

$$\mathbf{F}(\mathbf{P}_k) = \begin{bmatrix} f_1(x_k, y_k) \\ f_2(x_k, y_k) \end{bmatrix}$$

Paso 2: Evaluar $\mathbf{J}(\mathbf{P}_k)$

$$\mathbf{J}(\mathbf{P}_k) = \begin{bmatrix} \partial f_1 / \partial x(x_k, y_k) & \partial f_1 / \partial y(x_k, y_k) \\ \partial f_2 / \partial x(x_k, y_k) & \partial f_2 / \partial y(x_k, y_k) \end{bmatrix}$$

Paso 3: Resolver el sistema lineal

$$\mathbf{J}(\mathbf{P}_k) * \Delta \mathbf{P} = -\mathbf{F}(\mathbf{P}_k)$$

Paso 4: Actualizar

$$\mathbf{P}_{\{k+1\}} = \mathbf{P}_k + \Delta \mathbf{P}$$

Paso 5: Verificar tolerancia

$$\|\mathbf{P}_{\{k+1\}} - \mathbf{P}_k\| < \text{tol} \quad \text{o} \quad \|\mathbf{P}_{\{k+1\}} - \mathbf{P}_k\| / \|\mathbf{P}_{\{k+1\}}\| < \text{tol}$$

⚠ CONSIDERACIONES:

- **Convergencia cuadrática** (muy rápida) cerca de la raíz
- Requiere calcular derivadas parciales (Jacobiano)
- Requiere resolver un sistema lineal en cada iteración
- El punto inicial debe estar "suficientemente cerca" de la raíz
- La matriz $\mathbf{J}$ debe ser **invertible** ($\det(\mathbf{J}) \neq 0$)

NR como caso particular de PF:

$$g_1(x,y) = x - [f_1(x,y) * \partial f_2 / \partial y - f_2(x,y) * \partial f_1 / \partial y] / \det(J)$$
$$g_2(x,y) = y - [f_2(x,y) * \partial f_1 / \partial x - f_1(x,y) * \partial f_2 / \partial x] / \det(J)$$

2. INTERPOLACIÓN POLINOMIAL {#2-interpolación}

2.1 Conceptos básicos

¿Qué es interpolar?

Dado un conjunto de puntos $\{(x_0, y_0), (x_1, y_1), ..., (x_n, y_n)\}$, queremos encontrar un **polinomio $p(x)$** que pase **exactamente** por todos esos puntos.

Condiciones de interpolación:

$$p(x_0) = y_0$$
$$p(x_1) = y_1$$
$$...$$
$$p(x_n) = y_n$$

Teorema fundamental:

Existe un **ÚNICO** polinomio de grado $\leq n$ que interpola $n+1$ puntos distintos.

Diferencia con ajuste:

INTERPOLACIÓN	AJUSTE
Pasa EXACTAMENTE por todos los puntos	Pasa CERCA de los puntos
$n+1$ puntos $\rightarrow$ polinomio grado $\leq n$	Muchos puntos $\rightarrow$ polinomio grado bajo
Captura todos los datos (incluso ruido)	Captura la tendencia general

2.2 Método directo: Matriz de Vandermonde

Planteamiento:

Queremos un polinomio:

$$p(x) = a_0 + a_1x + a_2x^2 + ... + a_nx^n$$

Las condiciones de interpolación generan un sistema lineal:

$$a_0 + a_1x_0 + a_2x_0^2 + ... + a_nx_0^n = y_0$$
$$a_0 + a_1x_1 + a_2x_1^2 + ... + a_nx_1^n = y_1$$
$$...$$

$$a_0 + a_1x_n + a_2x_n^2 + \dots + a_nx_n^n = y_n$$

Forma matricial:

$$Va = y$$

Donde **V** es la **matriz de Vandermonde**:

$$V = \begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix}$$

Solución:

$$a \equiv V^{-1} * y$$

Resolvemos con cualquier método para sistemas lineales (Gauss, LU, etc.).

⚠ PROBLEMA:

La matriz de Vandermonde puede estar **muy mal condicionada** (números muy grandes y pequeños) → errores numéricos.

2.3 Interpolación de Lagrange

Idea fundamental:

En vez de resolver un sistema, construimos directamente el polinomio usando una **base especial**.

Polinomios base de Lagrange:

Para cada punto x_k , definimos:

$$L_{n,k}(x) = \frac{[(x - x_0)(x - x_1)\dots(x - x_{k-1})(x - x_{k+1})\dots(x - x_n)]}{[(x_k - x_0)(x_k - x_1)\dots(x_k - x_{k-1})(x_k - x_{k+1})\dots(x_k - x_n)]}$$

Es decir: **numerador** tiene todos los $(x - x_j)$ excepto $(x - x_k)$

denominador tiene todos los $(x_k - x_j)$ excepto $(x_k - x_k)$

Propiedades clave:

$$\begin{aligned} L_{n,k}(x_j) &\equiv 1 \quad \text{si } j \equiv k \\ L_{n,k}(x_j) &\equiv 0 \quad \text{si } j \neq k \end{aligned}$$

¡El polinomio $L_{n,k}$ vale 1 en x_k y 0 en todos los demás nodos!

Fórmula de Lagrange:

$$p_n(x) \equiv \sum_{k=0}^n y_k \cdot L_{n,k}(x)$$

O más explícito:

$$p_n(x) = y_0 \cdot L_{n,0}(x) + y_1 \cdot L_{n,1}(x) + \dots + y_n \cdot L_{n,n}(x)$$

Ejemplo con 3 puntos (n=2):

Puntos: $(x_0, y_0), (x_1, y_1), (x_2, y_2)$

$$L_{2,0}(x) = [(x - x_1)(x - x_2)] / [(x_0 - x_1)(x_0 - x_2)]$$

$$L_{2,1}(x) = [(x - x_0)(x - x_2)] / [(x_1 - x_0)(x_1 - x_2)]$$

$$L_{2,2}(x) = [(x - x_0)(x - x_1)] / [(x_2 - x_0)(x_2 - x_1)]$$

$$p_2(x) = y_0 \cdot L_{2,0}(x) + y_1 \cdot L_{2,1}(x) + y_2 \cdot L_{2,2}(x)$$

Ventajas de Lagrange:

- ✓ No requiere resolver sistemas lineales
- ✓ Fórmula explícita
- ✓ Fácil de programar
- ✓ Numéricamente más estable que Vandermonde

Desventajas:

- ✗ Si agregamos un punto nuevo, hay que recalcular TODO
- ✗ No es eficiente para evaluar en muchos puntos

Error de interpolación:

Si $f(x)$ es la función real y $p_n(x)$ es el interpolante:

$$|f(x) - p_n(x)| \leq [M/(n+1)!] \cdot |(x - x_0)(x - x_1)\dots(x - x_n)|$$

Donde $M = \max |f^{(n+1)}(\xi)|$ para algún ξ entre el menor y mayor x_i .

⚠ Fenómeno de Runge:

Con nodos equiespaciados y grado alto, el polinomio puede **oscilar mucho** en los extremos del intervalo, aunque pase por todos los puntos.

Solución: Usar nodos de Chebyshev (no equiespaciados).

3. AJUSTE DE CURVAS - MÍNIMOS CUADRADOS {#3-ajuste}

3.1 Conceptos básicos

Diferencia fundamental con interpolación:

INTERPOLACIÓN	AJUSTE
Datos exactos	Datos con ruido/error experimental
Polinomio pasa POR los puntos	Curva pasa CERCA de los puntos
Grado alto (n puntos $\rightarrow$ grado n-1)	Grado bajo (captura tendencia)

Problema del ajuste:

Dados N puntos $\{(x_k, y_k), k=1, \dots, N\}$, queremos encontrar una función $f(x)$ que mejor se ajuste a los datos en algún sentido.

¿Qué significa "mejor ajuste"?

Minimizar alguna medida del **error total**.

3.2 Método de Mínimos Cuadrados**Residuos o errores:**

Para cada punto:

$$e_k = f(x_k) - y_k$$

El residuo es la diferencia vertical entre la curva y el punto.

Criterio de mínimos cuadrados:

Minimizamos la **suma de los cuadrados de los residuos**:

$$E = \sum_{k=1}^N e_k^2 = \sum_{k=1}^N [f(x_k) - y_k]^2$$

¿Por qué cuadrados?

- Los errores positivos y negativos no se cancelan
- Da más peso a errores grandes (penaliza outliers)
- Matemáticamente conveniente (derivable)

Error Cuadrático Medio (ECM):

$$ECM = \sqrt{E/N} = \sqrt{[\sum (f(x_k) - y_k)^2 / N]}$$

Sirve para **comparar** diferentes ajustes.

3.3 Regresión Lineal Simple

Modelo:

$$f(x) = Ax + B$$

Queremos encontrar **A** (pendiente) y **B** (ordenada) que minimicen E.

Ecuaciones Normales de Gauss:

Para minimizar E, derivamos respecto a A y B e igualamos a cero. Esto da el sistema:

$$[\sum x_k^2] * A + [\sum x_k] * B = \sum x_k y_k$$

$$[\sum x_k] * A + N * B = \sum y_k$$

O en forma matricial:

$$\begin{bmatrix} \sum x_k^2 & \sum x_k \end{bmatrix} \begin{bmatrix} A \\ B \end{bmatrix} = \begin{bmatrix} \sum x_k y_k \end{bmatrix}$$

$$\begin{bmatrix} \sum x_k & N \end{bmatrix} \begin{bmatrix} A \\ B \end{bmatrix} = \begin{bmatrix} \sum y_k \end{bmatrix}$$

Solución directa (fórmulas):

$$A = [N * \sum x_k y_k - \sum x_k * \sum y_k] / [N * \sum x_k^2 - (\sum x_k)^2]$$

$$B = [\sum y_k * \sum x_k^2 - \sum x_k * \sum x_k y_k] / [N * \sum x_k^2 - (\sum x_k)^2]$$

Ejemplo paso a paso:

Datos: (1, 1), (2, 3), (3, 4)

Paso 1: Calcular sumatorias

$$N = 3$$

$$\sum x_k = 1 + 2 + 3 = 6$$

$$\sum y_k = 1 + 3 + 4 = 8$$

$$\sum x_k^2 = 1 + 4 + 9 = 14$$

$$\sum x_k y_k = 1 * 1 + 2 * 3 + 3 * 4 = 19$$

Paso 2: Armar ecuaciones normales

$$14A + 6B = 19$$

$$6A + 3B = 8$$

Paso 3: Resolver

$$A = 1.5$$

$$B = -0.333...$$

Recta: $y = 1.5x - 0.333$

3.4 Ajuste Polinomial

Modelo general:

$$p(x) = a_0 + a_1x + a_2x^2 + \dots + a_mx^m$$

Con $m < n-1$ (grado menor que interpolación).

Ecuaciones normales (forma matricial):

$$[V^T V] a = V^T y$$

Donde V es tipo Vandermonde pero puede tener más filas que columnas (más puntos que coeficientes).

Sistema a resolver:

$$\begin{bmatrix} \sum 1 & \sum x_k & \sum x_k^2 & \dots & \sum x_k^m \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum y_k \\ \sum x_k y_k \\ \sum x_k^2 y_k \\ \vdots \\ \sum x_k^m y_k \end{bmatrix}$$

Casos especiales:

Recta por el origen: $y = Ax$

$$A \equiv \sum x_k y_k / \sum x_k^2$$

Parábola con vértice en y: $y = Ax^2 + B$

$$\begin{aligned} \sum x_k^4 A + \sum x_k^2 B &= \sum x_k^2 y_k \\ \sum x_k^2 A + N B &= \sum y_k \end{aligned}$$

3.5 Ajuste con Funciones Base Arbitrarias

Modelo general:

$$g(x) = c_1\phi_1(x) + c_2\phi_2(x) + \dots + c_m\phi_m(x)$$

Donde $\phi_i(x)$ son **funciones base** (pueden ser cualquier función).

Ejemplos de bases:

- Polinomial: $\{1, x, x^2, x^3, \dots\}$
- Trigonométrica: $\{1, \sin(x), \cos(x), \sin(2x), \dots\}$
- Exponencial: $\{1, e^x, e^{(2x)}, \dots\}$
- Mixta: $\{1, x, \sin(x), xe^x, \dots\}$

Ecuaciones normales:

$$[\Phi^T \Phi] c = \Phi^T y$$

Donde Φ es la matriz de evaluaciones:

$$\Phi = \begin{bmatrix} \phi_1(x_1) & \phi_2(x_1) & \dots & \phi_m(x_1) \\ \phi_1(x_2) & \phi_2(x_2) & \dots & \phi_m(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_n) & \phi_2(x_n) & \dots & \phi_m(x_n) \end{bmatrix}$$

Sistema resultante:

$$[\sum \phi_i(x_k) \phi_j(x_k)]_{i,j} c = [\sum \phi_i(x_k) y_k]_i$$

RESUMEN DE FÓRMULAS IMPORTANTES

Punto Fijo (convergencia):

$$|\partial g_1 / \partial x| + |\partial g_1 / \partial y| < 1$$

$$|\partial g_2 / \partial x| + |\partial g_2 / \partial y| < 1$$

Newton-Raphson:

$$P_{k+1} \equiv P_k - [J(P_k)]^{-1} * F(P_k)$$

Lagrange (3 puntos):

$$p_2(x) = y_0 * [(x-x_1)(x-x_2)] / [(x_0-x_1)(x_0-x_2)]$$

$$+ y_1 * [(x-x_0)(x-x_2)] / [(x_1-x_0)(x_1-x_2)]$$

$$+ y_2 * [(x-x_0)(x-x_1)] / [(x_2-x_0)(x_2-x_1)]$$

Regresión lineal:

$$A = [N * \sum x_k y_k - \sum x_k * \sum y_k] / [N * \sum x_k^2 - (\sum x_k)^2]$$

$$B = [\sum y_k * \sum x_k^2 - \sum x_k * \sum x_k y_k] / [N * \sum x_k^2 - (\sum x_k)^2]$$

Error cuadrático medio:

$$ECM = \sqrt{[\Sigma(f(x_k) - y_k)^2 / N]}$$

CONSEJOS PARA EL PARCIAL

Para SENL:

1. Siempre graficar primero (visualizar raíces)
2. Verificar condiciones de convergencia
3. Probar varios puntos iniciales si es necesario
4. En Newton-Raphson: calcular bien el Jacobiano

Para Interpolación:

1. Recordar: $n+1$ puntos $\rightarrow$ polinomio grado $\leq n$
2. Lagrange es más fácil que Vandermonde
3. Cuidado con el fenómeno de Runge (grado alto)
4. Siempre graficar el polinomio con los puntos

Para Ajuste:

1. Diferenciarlo claramente de interpolación
2. Las ecuaciones normales son clave
3. Calcular siempre el ECM para comparar
4. Graficar datos + curva ajustada

¡Éxito en el parcial Agu! 