

BASE MATEMATICA PARA PAGERANK

Todo lo que necesitas saber antes de leer Moler Cap. 2.11

Materia: Metodos y Computos Numericos — UCA Rosario | Alumno: Formenti, Agustin | Proyecto: Coloquio Final — PageRank y Cadenas de Markov (Propuesta 09)

Fuente principal: Moler, C.B. — Numerical Computing with MATLAB, SIAM, 2004, Cap. 2.11 pp. 74-81 | Redaccion asistida por Claude AI (Anthropic) — contenido matematico verificado contra la fuente.

Este documento explica, desde cero, cada concepto matematico que aparece en las paginas 74-81 del libro de Moler. Cada seccion esta citada con la pagina exacta donde ese concepto es usado por Moler. Cuando un concepto **no esta en Moler pero es necesario para entenderlo**, se indica de que fuente complementaria obtenerlo.

#	Concepto	Nivel	Aparece en Moler
1	Vectores y matrices	Base	p. 74 (G, x)
2	Multiplicacion matriz-vector	Base	p. 75 ($x = A*x$)
3	Sumas de columnas y diagonal	Base	p. 76 ($c = \text{sum}(G), D$)
4	Grafos dirigidos	Intermedio	p. 74 ($G, \text{in/out-degree}$)
5	Probabilidad y distribucion	Intermedio	p. 74-75 (x como prob.)
6	Matriz estocastica	Intermedio	p. 74-75 (A)
7	Sistemas lineales $Ax = b$	Intermedio	p. 77 (backslash)
8	Sistema homogeneo y singular	Intermedio	p. 75 ($(I-A)x=0$)
9	Autovalores y autovectores	Avanzado	p. 75 ($x = A*x, \text{lambda}=1$)
10	Teorema Perron-Frobenius	Avanzado	p. 75 (unicidad)
11	Metodo de la Potencia	Avanzado	p. 75-76 (iteracion)
12	Matrices sparse	Implementacion	p. 77 (sparse, spdiags)

PARTE 1 — NIVEL BASE: Vectores y Matrices

1. Que es un vector

Un vector es una lista ordenada de numeros. En MATLAB se escribe como una columna con punto y coma entre los elementos. En PageRank, el vector x es la lista de importancias de cada pagina: el elemento $x(i)$ representa la fraccion del tiempo que un navegante aleatorio pasa en la pagina i .

"x is the state vector of the Markov chain and is Google's PageRank. The elements of x are all positive and less than one."

Fuente: Moler, p. 75

```
% x es el vector PageRank: un numero por pagina
x = [0.2675; 0.2524; 0.1323; 0.1697; 0.0625; 0.1156]
% x(1) = 0.2675 significa que la pagina 1 es visitada el 26.75% del tiempo
% sum(x) = 1 siempre (es una distribucion de probabilidad)
```

2. Que es una matriz

Una matriz es una tabla rectangular de numeros con filas y columnas. En PageRank, la matriz central es G , la matriz de conectividad: $G(i,j) = 1$ si existe un hyperlink de la pagina j hacia la pagina i , y $G(i,j) = 0$ si no existe.

"Let G be the n-by-n connectivity matrix of a portion of the Web, that is, $g_{ij} = 1$ if there is a hyperlink to page i from page j and $g_{ij} = 0$ otherwise."

Fuente: Moler, p. 74

```
% G(i,j) = 1: existe link de pagina j HACIA pagina i
% OJO: la convencion es (destino, origen) – no al reves
G =
0 0 0 1 0 1 % fila 1: paginas que apuntan A pagina 1
1 0 0 0 0 0 % fila 2: paginas que apuntan A pagina 2
0 1 0 0 0 0
0 1 1 0 0 0
0 0 1 0 0 0
0 0 1 0 1 0
```

3. Multiplicacion matriz-vector ($A \cdot x$)

El producto de una matriz A por un vector x produce un nuevo vector. El elemento i del resultado es la suma de la fila i de A multiplicada elemento a elemento por x . **Esta operacion es el nucleo del Metodo de la Potencia:** repetir $x = A \cdot x$ hasta convergencia.

"For modest n , an easy way to compute x in MATLAB is to start with some approximate solution... $x = \text{ones}(n,1)/n$. Then simply repeat the assignment statement $x = A \cdot x$ until successive vectors agree to within a specified tolerance."

Fuente: Moler, p. 75

```
% Ejemplo con A 2x2 y x de 2 elementos
A = [2 1; 3 4]
x = [1; 2]
resultado = A*x
% resultado(1) = 2*1 + 1*2 = 4
% resultado(2) = 3*1 + 4*2 = 11
% En PageRank: cada iteracion x = A*x redistribuye la 'importancia'
```

4. Suma de columnas y matriz diagonal D

La suma de la columna j de G es el **out-degree** de la pagina j : cuantos links tiene esa pagina. Moler guarda estos valores en el vector c y construye una matriz diagonal D donde $D(j,j) = 1/c(j)$. Multiplicar $G \cdot D$ normaliza cada columna de G para que sume 1.

"Once G has been generated, we need to scale it by its column sums. $c = \text{sum}(G)$. It is best to use the `spdiags` function to create a sparse diagonal matrix. $D = \text{spdiags}(1./c', 0, n, n)$."

Fuente: Moler, p. 76-77

```
c = sum(G) % sumas de columnas: c(j) = out-degree de pagina j
% c = [1 2 3 1 1 1] para el ejemplo de 6 nodos

D = spdiags(1./c', 0, n, n) % matriz diagonal sparse
% D(1,1) = 1/1 = 1.0
% D(2,2) = 1/2 = 0.5
% D(3,3) = 1/3 = 0.33...
% G*D: cada columna j de G queda dividida por c(j)
```

5. Matriz identidad (I)

La matriz identidad tiene 1s en la diagonal y 0s en el resto. Multiplicar cualquier matriz o vector por I lo deja igual — es el '1' del algebra matricial. En PageRank aparece en la formula central: $I - p \cdot G \cdot D$.

" $I = \text{speye}(n,n)$ "

Fuente: Moler, p. 77 (codigo del ejemplo)

```
I = speye(n, n) % identidad sparse de n x n
% speye es la version sparse de eye(n,n)
% I*x = x siempre, para cualquier x
% I - p*G*D: restar la 'influencia de los links' a la identidad
```

PARTE 2 — NIVEL INTERMEDIO: Probabilidad y Sistemas Lineales

6. Grafos dirigidos: nodos, aristas, in-degree y out-degree

Un grafo dirigido es un conjunto de **nodos** (en PageRank: paginas web) conectados por **aristas con direccion** (en PageRank: hyperlinks). Una arista va DE un nodo A otro nodo — tiene origen y destino. El **in-degree** de un nodo es la cantidad de aristas que llegan a el. El **out-degree** es la cantidad de aristas que salen. Nodos con alto in-degree tienden a tener alto PageRank.

"The quantities r_j and c_j are the in-degree and out-degree of the j th page."

Fuente: Moler, p. 74

```
% En el ejemplo de 6 nodos (Moler p. 78-79):
% alpha: in-degree = 2, out-degree = 1 -> PageRank = 0.2675 (mayor)
% rho: in-degree = 1, out-degree = 1 -> PageRank = 0.0625 (menor)
% beta sube porque 'basks in alpha's glory': alpha le apunta

% NOTA: G(i,j) representa una arista j -> i
% Columna j de G = outlinks de la pagina j
% Fila i de G = inlinks de la pagina i
```

Si no sabes grafos: buscar 'grafos dirigidos' en cualquier libro de matematica discreta. Es el concepto mas intuitivo del proyecto — se entiende en 15 minutos con un dibujo.

7. Distribucion de probabilidad

Una distribucion de probabilidad es un vector donde todos los elementos son positivos y suman exactamente 1. En PageRank, el vector x ES una distribucion: $x(i)$ es la probabilidad de que el navegante aleatorio este en la pagina i en un momento dado.

"The limiting probability that an infinitely dedicated random surfer visits any particular page is its PageRank."

Fuente: Moler, p. 74

```
x = [0.2675; 0.2524; 0.1323; 0.1697; 0.0625; 0.1156]
sum(x) % = 1.0000 siempre
all(x > 0) % = 1 siempre (todos positivos)

% Interpretacion: si el surfer navega por siempre,
% visita la pagina 1 el 26.75% del tiempo,
% la pagina 5 solo el 6.25% del tiempo.
```

8. Matriz estocastica (por columnas)

Una matriz estocastica por columnas tiene todas las columnas que suman 1 y todos los elementos mayores o iguales a cero. Cada columna j es una distribucion de probabilidad: 'si estoy en la pagina j , con que probabilidad voy a cada otra pagina'. La matriz A de Moler ES una matriz estocastica.

"The matrix A is the transition probability matrix of the Markov chain. Its elements are all strictly between zero and one and its column sums are all equal to one."

Fuente: Moler, p. 74-75

```
% La columna 1 de A en el ejemplo de Moler (p. 78):
% A(:,1) = [0.025; 0.875; 0.025; 0.025; 0.025]
% Interpretation: desde pagina 1, con prob 0.875 vas a pagina 2 (su unico link)
% con prob 0.025 teleportas a cualquier otra pagina
sum(A(:,1)) % = 1.0000 siempre

% Como se construye A (Moler p. 76):
p = 0.85; delta = (1-p)/n;
A = p*G*D + delta % G*D normaliza, delta agrega teleportacion
```

9. Sistema de ecuaciones lineales $Ax = b$

Un sistema lineal es un conjunto de ecuaciones donde las incognitas aparecen solo multiplicadas por constantes — sin potencias, sin funciones. En MATLAB se resuelve con el operador backslash (barra invertida). En PageRank, el calculo central es resolver el sistema lineal:

```
x = (I - p*G*D) \ (delta*e) % operador backslash de MATLAB
% Moler, p. 77
```

*"The statements $p=.85$; $\text{delta}=(1-p)/n$; $e=\text{ones}(n,1)$; $I=\text{speye}(n,n)$; $x=(I-p*G*D)\backslash(\text{delta}*e)$ compute PageRank by solving the sparse linear system with Gaussian elimination."*

Fuente: Moler, p. 76-77

El backslash hace **eliminacion gaussiana** automaticamente — no necesitas implementarla. Solo necesitas entender QUE hace: encuentra el unico vector x que satisface $(I - p*G*D)*x = \text{delta}*e$.

```
% Ejemplo simple de sistema lineal:
A = [2 1; 5 7]; b = [11; 13];
x = A \ b % MATLAB resuelve: encuentra x tal que A*x = b
% x = [7.36; -3.72] (aproximado)
% Verificacion: A*x deberia ser igual a b
norm(A*x - b) % debe ser casi 0
```

10. Sistema homogéneo y sistema singular

Sistema homogéneo: cuando $b = 0$, es decir, $Ax = 0$. Tiene infinitas soluciones proporcionales entre sí (si A es singular). **Sistema singular:** cuando la matriz A no tiene inversa (su determinante es 0). PageRank se formula exactamente como un sistema singular homogéneo:

"The vector x is the solution to the singular, homogeneous linear system $(I - A)x = 0$."

Fuente: Moler, p. 75

```
% (I - A)x = 0 es el sistema homogéneo
% I - A es singular porque lambda=1 es autovalor de A
% det(I - A) = 0 (en teoría exacta)

% Por eso Moler usa la versión equivalente NO singular:
x = (I - p*G*D) \ (delta*e) % p < 1 => NO singular
% 'As long as p is strictly less than one, the coefficient matrix
% I-p*G*D is nonsingular' - Moler, p. 76
```

Por qué singular? Porque $\lambda = 1$ siempre es autovalor de A (toda matriz estocástica lo tiene). Eso implica que $\det(I - A) = 0$. Moler lo resuelve con el truco de $p < 1$ que desplaza el autovalor.

PARTE 3 — NIVEL AVANZADO: Autovalores y Metodo de la Potencia

11. Autovalores y autovectores

Dado una matriz cuadrada A , un **autovector** es un vector x (no nulo) que al multiplicarlo por A solo cambia de escala — no de direccion. El escalar λ que produce ese cambio de escala se llama **autovalor**. La ecuacion es: $Ax = \lambda x$. **El PageRank es el autovector de A asociado al autovalor $\lambda = 1$.**

```
% Definicion:  $Ax = \lambda x$ 
% Si  $\lambda = 1$ :  $Ax = x \Rightarrow$  el vector no cambia con  $A$ 
% Eso significa que  $x$  es una distribucion ESTACIONARIA:
% si el surfer esta segun  $x$ , despues de un paso sigue segun  $x$ 

% En PageRank:  $Ax = x$  con  $\sum(x) = 1$  y  $x > 0$ 
%  $x$  es el PageRank: la distribucion estacionaria del surfer aleatorio
```

Por que $\lambda = 1$ para PageRank? Porque A es estocastica. Para CUALQUIER matriz estocastica, $\lambda = 1$ es siempre autovalor. La demostracion: $\sum(Ax) = \sum(x)$ para toda x (las columnas de A suman 1), por lo tanto la 'masa de probabilidad' se conserva en cada multiplicacion. Eso implica que $\lambda = 1$ existe.

Si no sabes autovalores: el libro de Moler, Cap. 10 los explica. Tambien cualquier libro de algebra lineal (ej. Strang, *Introduction to Linear Algebra*). Para el coloquio alcanza con entender la definicion $Ax = \lambda x$ y saber que $\lambda=1$ es el relevante.

12. Teorema de Perron-Frobenius

Es el teorema que garantiza que PageRank existe, es unico y tiene sentido como probabilidad. Moler lo cita directamente para justificar que el problema tiene solucion. El teorema dice: para matrices con todos sus elementos positivos (o ciertas matrices no-negativas con propiedades de conectividad), el autovalor de maximo modulo es unico, real y positivo, y su autovector tiene todos los elementos positivos.

"An important result in matrix theory known as the Perron-Frobenius theorem applies to such matrices. It concludes that a nonzero solution of the equation $[x = Ax]$ exists and is unique to within a scaling factor. If this scaling factor is chosen so that $[\sum(x) = 1]$, then x is the state vector of the Markov chain and is Google's PageRank. The elements of x are all positive and less than one."

Fuente: Moler, p. 75

```
% Lo que garantiza Perron-Frobenius para PageRank:
% 1.  $\lambda_{\max} = 1$  (autovalor dominante)
% 2. Es UNICO (no hay otro autovector independiente con  $\lambda=1$ )
% 3.  $x(i) > 0$  para todo  $i$  (todos los PageRanks son positivos)
% 4.  $\sum(x) = 1$  al normalizar (es una distribucion de probabilidad valida)

% Por eso Google puede publicar UN ranking unico y no ambiguo
```

Para la consulta: no necesitas demostrar el teorema. Si te preguntan 'que garantiza la existencia de solucion', respondes: 'El Teorema de Perron-Frobenius, citado por Moler en la pagina 75, garantiza que la solucion existe, es unica y tiene todos los elementos positivos porque A es una matriz estocastica con todos los elementos estrictamente positivos.'

13. Metodo de la Potencia: como y por que converge

El Metodo de la Potencia es el algoritmo iterativo para encontrar el autovector dominante (el asociado al autovalor de mayor modulo). El algoritmo es: inicializar x , luego repetir $x = A \cdot x$ y normalizar. Converge porque el autovalor dominante ($\lambda_1 = 1$) 'aplasta' a todos los demas ($|\lambda_k| < 1$ para $k \geq 2$). La tasa de convergencia es $|\lambda_2| / |\lambda_1| = |\lambda_2|$.

"This is known as the power method and is about the only possible approach for very large n . In practice, the matrices G and A are never actually formed. One step of the power method would be done by one pass over a database of Web pages."

Fuente: Moler, p. 75-76

```
% Algoritmo basico del Metodo de la Potencia (Moler p. 75):
x = ones(n, 1) / n; % inicializacion uniforme
tol = 1e-8;
for iter = 1:1000
    x_nuevo = A * x;
    x_nuevo = x_nuevo / sum(x_nuevo); % mantener sum = 1
    if norm(x_nuevo - x) < tol
        break
    end
    x = x_nuevo;
end
% Converge porque  $|\lambda_2| \leq 0.85 \Rightarrow \text{error} \sim 0.85^{\text{iter}}$ 
```

Por que inicializar con $\text{ones}(n,1)/n$? Sin informacion previa, todos los nodos son equiprobables. Es la distribucion uniforme — la mas neutral. Moler lo menciona en p. 75: 'start with some approximate solution... or $x = \text{ones}(n,1)/n$ '.

Por que converge? Porque en cada multiplicacion $x = A \cdot x$, la componente del autovector con $\lambda=1$ se mantiene, mientras que las componentes de los otros autovectores se achican por un factor $|\lambda_k| < 1$ en cada paso. Para PageRank con $p=0.85$, el segundo autovalor satisface $|\lambda_2| \leq 0.85$, por lo que el error decrece geometricamente: $\text{error}_k \sim 0.85^k$.

PARTE 4 — IMPLEMENTACION: Matrices Sparse en MATLAB

14. Que es una matriz sparse y por que importa

Una matriz sparse (dispersa) es aquella donde la gran mayoría de los elementos son cero. En lugar de almacenar los $n \times n$ elementos, MATLAB solo almacena los no-ceros y sus posiciones (fila, columna). Para una red de $n = 3.000.000.000$ paginas, una matriz densa requeriria 9×10^{18} numeros — imposible. Con sparse, solo se guardan los links reales (aprox. 15×10^9 para la web).

"The matrix G can be huge, but it is very sparse. [...] A sparse matrix is stored in a data structure that requires memory only for the nonzero elements and their indices."

Fuente: Moler, p. 74 y p. 77

```
% Crear G sparse a partir de los indices de los links
i = [2 3 4 4 5 6 1 6 1] % indices de fila (destinos)
j = [1 2 2 3 3 3 4 5 6] % indices de columna (origenes)
n = 6
G = sparse(i, j, 1, n, n) % 1 en posicion (i(k), j(k)) para cada k

% Visualizar estructura sparse:
spy(G) % muestra donde estan los no-ceros
nnz(G) % cantidad de no-ceros = cantidad de links
full(G) % ver la matriz completa (solo para n chico)
```

15. spdiags: matriz diagonal sparse

spdiags crea una matriz diagonal sparse de forma eficiente. Se usa para construir D, la matriz de normalizacion. spdiags(v, 0, n, n) crea una matriz $n \times n$ con el vector v en la diagonal y ceros en el resto.

*"D = spdiags(1./c',0,n,n). The sparse matrix product G*D will then be computed efficiently."*

Fuente: Moler, p. 77

```
c = full(sum(G)) % out-degrees: c = [1 2 3 1 1 1]
D = spdiags(1./c', 0, n, n)
% D es diagonal: D(j,j) = 1/c(j)
% D(1,1)=1/1=1.0, D(2,2)=1/2=0.5, D(3,3)=1/3=0.333...

% G*D normaliza columnas: la columna j de G*D suma 1
% Equivale a dividir cada columna de G por su suma
% (pero spdiags es mas eficiente que hacerlo con un loop)
```

16. La formula completa de PageRank ensamblada

Cada concepto anterior contribuye a una linea especifica del codigo de Moler. Aca se muestra la formula completa con la referencia de cada componente:

```
% =====  
% CODIGO COMPLETO DE PAGERANK (Moler, p. 77)  
% =====  
  
% --- NIVEL 1 (vectores/matrices) ---  
i = [2 3 4 4 5 6 1 6 1] % indices destino  
j = [1 2 2 3 3 3 4 5 6] % indices origen  
n = 6 % cantidad de paginas  
G = sparse(i, j, 1, n, n) % matriz de conectividad sparse  
  
% --- NIVEL 1 (sumas de columnas y diagonal) ---  
c = full(sum(G)) % out-degrees  
D = spdiags(1./c', 0, n, n) % D(j,j) = 1/out-degree(j)  
I = speye(n, n) % identidad sparse  
e = ones(n, 1) % vector de unos  
  
% --- NIVEL 2 (probabilidades) ---  
p = 0.85 % prob de seguir un link  
delta = (1-p)/n % prob de teleportacion = 0.025  
  
% --- NIVEL 3 (sistema lineal no singular) ---  
x = (I - p*G*D) \ (delta*e) % resuelve el sistema  
  
% --- RESULTADO ---  
% x = [0.2675; 0.2524; 0.1323; 0.1697; 0.0625; 0.1156]  
% Verificacion: sum(x) debe ser 1.0 (aprox)
```

PARTE 5 — LO QUE NO ESTA EN MOLER PERO ES NECESARIO

Moler asume cierto conocimiento previo que no explica en el Cap. 2.11. Estos conceptos son necesarios para entender el capitulo pero no estan ahi. Se indica donde encontrarlos.

Grafos dirigidos (definicion formal)

Moler usa grafos sin definirlos. Para entenderlos bien: cualquier libro de matematica discreta o el cap. inicial de cualquier libro de algoritmos (ej. Cormen, *Introduction to Algorithms*, Cap. 22). Con una busqueda en YouTube de 'directed graphs' se entiende en 15 minutos.

Fuente: No esta en Moler. Buscar en cualquier fuente de matematica discreta.

Eliminacion Gaussiana (que hace el backslash)

Moler usa el backslash sin explicarlo en el Cap. 2.11. Lo explica en el Cap. 2.1-2.7 del mismo libro (pp. 53-63). Para el coloquio alcanza saber que resuelve $Ax = b$ y que usa pivoteo parcial.

Fuente: Moler, Cap. 2.1-2.7, pp. 53-63.

Cadenas de Markov (teoria formal)

Moler menciona el nombre pero no desarrolla la teoria completa. Para una explicacion mas profunda: cualquier libro de probabilidad que cubra procesos estocasticos. Para el coloquio alcanza con la interpretacion intuitiva: proceso que salta entre estados segun probabilidades de transicion, y que tiene una distribucion estacionaria unica si es ergodico.

Fuente: No esta desarrollado en Moler. Para profundizar: Feller, *An Introduction to Probability Theory*, o cualquier libro de probabilidad con procesos de Markov.

Teorema Perron-Frobenius (demostracion)

Moler lo enuncia pero no lo demuestra. Para el coloquio no se necesita la demostracion — solo saber enunciarlo y aplicarlo. Si los profesores piden mas detalle: Trefethen & Bau, *Numerical Linear Algebra*, SIAM 2022 (es uno de los libros citados en el modelo de coloquio).

Fuente: Moler lo enuncia en p. 75 sin demostracion. Ver Trefethen & Bau si se necesita profundidad.

Convergencia del Metodo de la Potencia (demostracion formal)

Moler explica intuitivamente que converge pero no da la demostracion. La demostracion usa la descomposicion espectral de A y el hecho de que $|\lambda_2| < \lambda_1 = 1$. Para el coloquio alcanza con: 'converge porque el segundo autovalor satisface $|\lambda_2| \leq \rho = 0.85$, por lo que el error decrece como 0.85^k en cada iteracion.'

Fuente: Moler, pp. 75-76 (descripcion). Para demostracion: Mathews & Fink, Cap. 9 (autovalores).

RESUMEN: Mapa de conceptos → paginas de Moler

Concepto	Donde aparece en Moler	Para que sirve
Vector x	p. 74-75, en toda formula	El PageRank: un numero por pagina
Matriz G (sparse)	p. 74, 77	Estructura de links de la web
Suma de columnas $c = \text{sum}(G)$	p. 76	Out-degree de cada pagina
Diagonal $D = \text{spdiags}(1./c',...)$	p. 77	Normaliza columnas de G
Identidad $I = \text{speye}(n,n)$	p. 77	Aparece en $(I - p*G*D)$
$p = 0.85$	p. 74, 76-77	Prob. de seguir un link
$\delta = (1-p)/n$	p. 76-77	Prob. de teleportacion
$e = \text{ones}(n,1)$	p. 77	Vector de unos
$(I - p*G*D) \backslash (\delta * e)$	p. 77	CALCULO PRINCIPAL del PageRank
Matriz $A = p*G*D + \delta$	p. 76-78	Matriz de transicion completa
$A*x = x$	p. 75	PageRank es autovector con $\lambda=1$
Perron-Frobenius	p. 75	Garantiza existencia y unicidad
Metodo de la Potencia	p. 75-76	Alternativa iterativa al backslash
Inverse iteration	p. 77-78	Sistema singular que igual funciona
$\text{spy}(G)$	p. 81 (Harvard500)	Visualizar estructura sparse

5 preguntas de autoevaluacion antes de leer Moler

Cuando termines de leer este documento, cierras Moler y te preguntás:

1. Que es PageRank en palabras simples, sin formulas?

Respuesta: La probabilidad de que un navegante aleatorio este en cada pagina. Moler p.74.

2. Por que la matriz A tiene columnas que suman 1?

Respuesta: Porque cada columna representa una distribucion de probabilidad de transicion. Moler p.74-75.

3. Que garantiza que exista una unica solucion?

Respuesta: El Teorema de Perron-Frobenius para matrices estocasticas. Moler p.75.

4. Por que funciona el Metodo de la Potencia?

Respuesta: Porque el autovalor dominante es $\lambda=1$ y todos los demas tienen $|\lambda| < 0.85$, por lo que converge. Moler p.75-76.

5. Por que $(I - p*G*D)$ si es invertible y $(I - A)$ no?

*Respuesta: Porque con $p < 1$ se desplaza el autovalor a $\lambda * p < 1$, haciendo la matriz no singular. Moler p.76.*

Fuente principal de todo este documento: Moler, C.B. — *Numerical Computing with MATLAB*, SIAM, 2004, Seccion 2.11 PageRank and Markov Chains, pp. 74-81. Redaccion y estructura: Claude AI (Anthropic). Todo el contenido matematico verificado contra la fuente.